

**PENCARIAN DOKUMEN KOMENTAR KASUS POLIO
BERBASIS SEMANTIC SEARCH MENGGUNAKAN SBERT
DAN FAISS
DENGAN CROSS-ENCODER RERANKING**

Disusun Untuk Memenuhi Tugas Mata Kuliah

Temu Kembali Informasi

Dosen Pengampuh :

Taufiqotul Bariyah, S.Kom.,M.IM.,MCE

Disusun Oleh :

[Nama Mahasiswa] : [NIM]

**DEPARTEMENT INFORMATIKA
UNIVERSITAS INTERNASIONAL SEMEN INDONESIA
GRESIK 2025/2026**

ABSTRAK

Penelitian ini membahas peningkatan sistem pencarian dokumen berbasis TF-IDF menjadi sistem hybrid yang mengintegrasikan Semantic Search dan Cross-Encoder Reranking, diterapkan pada koleksi 50 komentar berbahasa Indonesia bertema kasus polio. Sistem baseline menggunakan TF-IDF dengan Vector Space Model dan Cosine Similarity. Sistem yang diusulkan menambahkan representasi vektor semantik menggunakan SBERT multilingual, pencarian kedekatan vektor menggunakan FAISS, serta penajaman hasil menggunakan Cross-Encoder Reranking berbasis model multilingual mmarco. Ketiga sistem dievaluasi menggunakan metrik Mean Average Precision (MAP), Mean Reciprocal Rank (MRR), dan Normalized Discounted Cumulative Gain (NDCG) pada lima ground-truth query yang disusun berdasarkan topik dominan dalam data.

[Bagian abstrak ini akan dilengkapi dengan ringkasan hasil dan temuan kuantitatif setelah tahap evaluasi penuh selesai dilakukan.]

Kata Kunci: Information Retrieval, TF-IDF, Semantic Search, SBERT, FAISS, Cross-Encoder Reranking, Komentar Kasus Polio

BAB 1

PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi informasi yang pesat menghasilkan jumlah data digital yang terus meningkat secara eksponensial, termasuk data tidak terstruktur berupa komentar masyarakat di media sosial. Pada penelitian sebelumnya, telah dibangun sistem pencarian dokumen berbasis TF-IDF (Term Frequency-Inverse Document Frequency) dan Cosine Similarity untuk mencari komentar warganet terkait kasus polio. Sistem tersebut terbukti berfungsi, namun memiliki keterbatasan mendasar: pencocokan yang dilakukan bersifat leksikal, sehingga query dan dokumen yang menggunakan kata berbeda dengan makna serupa — misalnya ‘lumpuh’, ‘cacat’, dan ‘kelumpuhan’ — tidak selalu dapat dipasangkan dengan tepat.

Untuk mengatasi keterbatasan tersebut, penelitian ini mengusulkan integrasi teknik Semantic Search berbasis deep learning embeddings dan Cross-Encoder Reranking ke dalam sistem yang telah ada. Dataset 50 dokumen yang sama dengan penelitian sebelumnya tetap digunakan agar performa sistem klasik dan modern dapat dibandingkan secara objektif dan terverifikasi pada kondisi data yang identik.

1.2 Rumusan Masalah

1. Bagaimana merancang dan mengimplementasikan sistem Semantic Search menggunakan SBERT dan FAISS pada dataset komentar kasus polio?
2. Bagaimana Cross-Encoder Reranking dapat meningkatkan presisi hasil pencarian dibandingkan Semantic Search saja?
3. Seberapa besar peningkatan relevansi sistem hybrid (Semantic Search + Reranking) dibandingkan sistem baseline TF-IDF, diukur menggunakan metrik MAP, MRR, dan NDCG?

1.3 Tujuan Penelitian

1. Mengimplementasikan pipeline Semantic Search menggunakan model SBERT multilingual dan basis data vektor FAISS.
2. Mengimplementasikan Cross-Encoder Reranking untuk menajamkan hasil pencarian dari tahap Semantic Search.

3. Membangun antarmuka pengguna (GUI) berbasis Python agar sistem dapat digunakan secara interaktif.

4. Mengevaluasi dan membandingkan performa tiga sistem — TF-IDF, Semantic Search, dan Hybrid + Reranking — menggunakan metrik MAP, MRR, dan NDCG pada lima ground-truth query.

1.4 Ruang Lingkup

Sistem dibangun menggunakan bahasa pemrograman Python. Koleksi dokumen terdiri dari 50 komentar dalam Bahasa Indonesia bertema kasus polio, identik dengan dataset pada penelitian sebelumnya. Penelitian mencakup tahapan preprocessing, pembangunan indeks (TF-IDF dan vektor semantik), pembobotan dan pencarian, reranking, hingga evaluasi kuantitatif menggunakan metrik Information Retrieval standar.

BAB 2

METODE

2.1 Dataset

Dataset terdiri dari 50 komentar berbahasa Indonesia bertema kasus polio, bersumber dari media sosial, disimpan dalam format Microsoft Excel (.xlsx). Komentar-komentar ini mencakup pengalaman pribadi terkait polio, sikap pro maupun kontra terhadap vaksin, informasi imunisasi, serta diskusi kebijakan kesehatan pemerintah.

2.2 Sistem Baseline: TF-IDF

Sistem baseline menggunakan pipeline preprocessing (case folding, penghapusan tanda baca, stopwords removal, dan stemming menggunakan algoritma Enhanced Confix Stripping dari library PySastrawi), pembangunan Inverted Index, pembobotan TF-IDF dengan log frequency weighting, serta pencarian menggunakan Vector Space Model dan Cosine Similarity.

$$\text{TF}\{\text{term}\}\text{weight} = 1 + \log_{10}(\text{tf}) \quad ; \quad \text{IDF}(t) = \log_{10}((N+1)/(\text{df}+1)) + 1$$

2.3 Semantic Search: SBERT dan FAISS

Semantic Search dirancang untuk mengatasi keterbatasan TF-IDF dalam menangkap makna. Setiap dokumen dan query diubah menjadi vektor embedding menggunakan model SBERT multilingual (paraphrase-multilingual-MiniLM-L12-v2), yang dipilih karena bersifat pre-trained, mendukung Bahasa Indonesia tanpa training tambahan, dan mampu menangkap kemiripan makna meskipun kata yang digunakan berbeda (mengatasi lexical gap).

Vektor-vektor dokumen disimpan pada index FAISS (Facebook AI Similarity Search) bertipe IndexFlatIP, yang berfungsi sebagai basis data vektor sekaligus mesin pencarian kedekatan. Saat menerima query, sistem meng-encode query menjadi vektor, kemudian FAISS mengembalikan sejumlah kandidat dokumen dengan vektor paling dekat sebagai hasil Semantic Search.

$$\text{doc_vectors} = \text{SBERT}(\text{documents}) \rightarrow \text{FAISS.add}(\text{doc_vectors}) \rightarrow \text{FAISS.search}(\text{SBERT}(\text{query}))$$

2.4 Cross-Encoder Reranking

Kandidat dokumen hasil Semantic Search diproses lebih lanjut menggunakan Cross-Encoder Reranking dengan model cross-encoder/mmarco-mMiniLMv2-L12-H384-v1 yang bersifat multilingual. Berbeda dari SBERT yang meng-encode query dan dokumen secara terpisah (bi-encoder), Cross-Encoder membaca pasangan query dan dokumen secara bersamaan sehingga dapat menilai relevansi dengan lebih presisi. Skor dari Cross-Encoder menentukan urutan akhir hasil pencarian pada sistem hybrid.

TF-IDF tidak digabungkan ke dalam pipeline Semantic Search dan Reranking. Ketiganya — TF-IDF, Semantic Search, dan Hybrid (Semantic Search + Reranking) — berjalan sebagai tiga sistem independen yang diuji pada query dan dataset yang sama, sehingga hasilnya dapat dibandingkan secara adil pada tahap evaluasi.

2.5 Antarmuka Pengguna (GUI)

Sistem dibangun sebagai aplikasi Python mandiri dengan antarmuka grafis interaktif menggunakan framework Streamlit, sehingga dapat dijalankan secara lokal dan didemonstrasikan secara langsung tanpa bergantung pada lingkungan notebook. Antarmuka memungkinkan pengguna memasukkan query dan membandingkan hasil pencarian dari ketiga sistem (TF-IDF, Semantic Search, dan Hybrid) secara berdampingan.

[Detail implementasi antarmuka — struktur halaman, komponen input/output, dan tangkapan layar aplikasi — akan dilengkapi setelah pengembangan GUI selesai.]

2.6 Ground-Truth Query dan Metrik Evaluasi

Evaluasi dilakukan menggunakan lima ground-truth query yang disusun berdasarkan topik-topik dominan dalam dataset, beserta daftar dokumen relevan yang ditentukan secara manual untuk masing-masing query:

1. “vaksin polio anak” — topik imunisasi dan manfaat vaksin bagi anak
2. “lumpuh cacat kaki” — dampak fisik akibat infeksi polio
3. “imunisasi puskesmas gratis” — layanan kesehatan pemerintah
4. “antivaksin berbahaya” — keresahan dan penolakan terhadap vaksin
5. “polio Indonesia bebas” — status eradikasi polio secara nasional

Ketiga sistem akan diuji pada kelima query tersebut, kemudian dihitung nilai MAP, MRR, dan NDCG@5 sebagai dasar perbandingan performa yang dipaparkan pada Bab 3.

$$\text{MRR} = (1/Q) \sum (1/\text{rank}_i) \quad \text{MAP} = (1/Q) \sum AP_i \quad \text{NDCG@k} = \text{DCG@k} / \text{IDCG@k}$$

BAB 3

HASIL EKSPERIMEN DAN ANALISIS

3.1 Statistik Koleksi Dokumen

Parameter	Nilai
Total dokumen (N)	50
Total term unik (vocabulary, setelah stemming)	654
Bahasa dokumen	Bahasa Indonesia
Topik	Komentar Kasus Polio

3.2 Hasil Sistem Baseline: TF-IDF

Sistem baseline TF-IDF telah diimplementasikan dan diuji pada dua contoh query sebagai berikut:

Query	Precision	Recall	F-Measure
vaksin polio anak	1.0000	0.7143	0.8333
lumpuh cacat kaki	0.6000	0.5000	0.5455

Hasil ini menunjukkan bahwa TF-IDF bekerja sangat baik pada query dengan kata kunci eksplisit dan sering muncul ('vaksin polio anak'), namun performanya menurun pada query dengan variasi kata yang lebih beragam ('lumpuh cacat kaki'). Pola ini menjadi motivasi utama pengembangan Semantic Search, yang diharapkan mampu menemukan dokumen relevan meski menggunakan istilah berbeda dari query.

3.3 Hasil Semantic Search (SBERT + FAISS)

[Bagian ini akan diisi dengan tabel Top-5 hasil pencarian untuk kelima ground-truth query menggunakan Semantic Search, beserta skor cosine similarity dari FAISS, setelah tahap implementasi dan pengujian selesai dilakukan.]

3.4 Hasil Sistem Hybrid (Semantic Search + Cross-Encoder Reranking)

[Bagian ini akan diisi dengan tabel Top-5 hasil pencarian setelah reranking, beserta skor relevansi dari Cross-Encoder, untuk kelima ground-truth query.]

3.5 Perbandingan Metrik Evaluasi Antar Sistem

Tabel berikut merangkum rencana perbandingan performa ketiga sistem menggunakan MAP, MRR, dan NDCG@5. Nilai aktual akan diisi setelah seluruh sistem selesai diimplementasikan dan diuji pada kelima ground-truth query.

Sistem	MAP	MRR	NDCG
TF-IDF (Baseline)	[TBD]	[TBD]	[TBD]
Semantic Search (SBERT + FAISS)	[TBD]	[TBD]	[TBD]
Hybrid (Semantic Search + Reranking)	[TBD]	[TBD]	[TBD]

3.6 Analisis Studi Kasus

[Bagian ini akan memaparkan contoh nyata kasus di mana Semantic Search dan/atau Reranking berhasil menemukan dokumen relevan yang gagal ditemukan oleh TF-IDF, sebagai bukti kualitatif manfaat pendekatan semantik — dilengkapi setelah eksperimen penuh selesai.]

BAB 4

KESIMPULAN DAN SARAN

4.1 Kesimpulan

Sistem baseline TF-IDF telah berhasil diimplementasikan dan menunjukkan performa baik pada query dengan kata kunci eksplisit, namun performanya menurun pada query dengan variasi kata yang lebih luas — mengonfirmasi keterbatasan pendekatan leksikal murni yang menjadi dasar pengembangan sistem ini.

Arsitektur sistem hybrid yang mengintegrasikan SBERT, FAISS, dan Cross-Encoder Reranking telah dirancang secara lengkap, dengan pemilihan model yang didasarkan pada pertimbangan teknis: kemampuan pre-trained untuk dataset kecil, dukungan multilingual untuk Bahasa Indonesia, dan kemampuan mengatasi lexical gap.

[Kesimpulan mengenai perbandingan kuantitatif performa ketiga sistem — apakah Hybrid + Reranking benar-benar mengungguli baseline TF-IDF, dan seberapa besar peningkatannya — akan dilengkapi setelah evaluasi penuh pada Bab 3 selesai dilakukan.]

4.2 Saran

1. Ekspansi koleksi dokumen ke lebih dari 50 dokumen untuk hasil evaluasi yang lebih representatif.
2. Implementasi query expansion menggunakan sinonim Bahasa Indonesia untuk meningkatkan recall sistem.
3. Eksplorasi metode pembobotan atau model embedding lain sebagai pembanding tambahan terhadap SBERT.
4. Pengembangan lebih lanjut pada antarmuka GUI agar mendukung visualisasi perbandingan hasil pencarian antar sistem secara berdampingan.

DAFTAR PUSTAKA

Manning, C. D., Raghavan, P., & Schütze, H. (2008). Introduction to Information Retrieval. Cambridge University Press.

Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing.

Johnson, J., Douze, M., & Jégou, H. (2017). Billion-scale similarity search with GPUs. IEEE Transactions on Big Data.

Salton, G., & Buckley, C. (1988). Term-Weighting Approaches in Automatic Text Retrieval. Information Processing & Management, 24(5), 513-523.

Asian, J., Williams, H. E., & Tahaghoghi, S. M. M. (2005). Stemming Indonesian. Proceedings of the 28th Australasian Conference on Computer Science, 267-275.

Sastrawi Python Library. (2021). PySastrawi: Indonesian Stemmer Library. <https://github.com/har07/PySastrawi>

Reimers, N. (2021). cross-encoder/mmarco-mMiniLMv2-L12-H384-v1. Hugging Face Model Hub.